Analyse e-commerce Olist avec SQL

Rapport de projet

Sezen Nisa Dikmen

Novembre 2026

En bref

Ce projet analyse près de 100 000 commandes réelles d'Olist, une marketplace brésilienne, passées entre 2016 et 2018. Les données ont été chargées dans une base PostgreSQL, puis interrogées en SQL pour répondre à 15 questions business.

Trois constats ressortent. La croissance vient de nouveaux clients, mais 97 % d'entre eux ne commandent qu'une seule fois. Les ventes stagnent depuis début 2018. Enfin, les retards de livraison font chuter les notes clients de 4,3 à 1,7 sur 5.

Outils : PostgreSQL 18, pgAdmin 4. **Données :** Brazilian E-Commerce Public Dataset by Olist (Kaggle).

1 Les données

Olist est une marketplace brésilienne : elle permet à de petits commerçants de vendre sur les grandes plateformes de e-commerce du pays. L'entreprise a publié sur Kaggle les données anonymisées de ses commandes de 2016 à 2018, en 9 fichiers CSV. Huit ont été chargés dans PostgreSQL ; le fichier de géolocalisation n'a pas été utilisé.

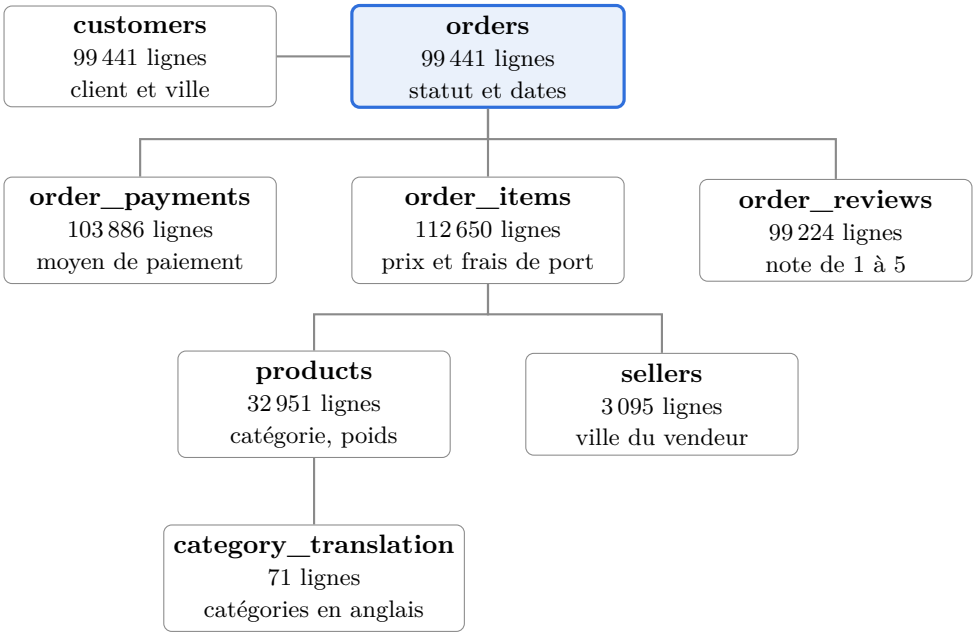


Figure 1: Modèle de données : la table `orders` relie le client, les articles, le paiement et l'avis.

Une commande appartient à un client et peut contenir plusieurs articles, plusieurs paiements et un avis. Chaque article renvoie à un produit et au vendeur qui l'a vendu.

2 La problématique

Comment Olist peut-il relancer sa croissance, alors que ses ventes mensuelles plafonnent depuis janvier 2018 ?

Pour y répondre, la question a été découpée en cinq sous-questions :

1. D'où vient la croissance passée : plus de clients, ou des paniers plus gros ?
2. Quels produits et quelles régions pèsent le plus dans le chiffre d'affaires ?
3. Les clients reviennent-ils acheter après une première commande ?
4. La livraison a-t-elle un effet sur la satisfaction des clients ?
5. L'entreprise dépend-elle d'un petit nombre de vendeurs ?

3 Méthode

3.1 Contrôle des données et périmètre

Avant toute analyse, les données ont été contrôlées. Ces vérifications ont fixé le périmètre de l'étude.

- 97 % des commandes ont le statut « livrée ». Seules celles-ci sont prises en compte dans le chiffre d'affaires.
- Les mois de septembre à décembre 2016 et de septembre à octobre 2018 comptent très peu de commandes. L'analyse couvre donc janvier 2017 à août 2018.
- Un même client reçoit un nouvel identifiant à chaque commande : 99 441 identifiants correspondent en réalité à 96 096 personnes. Les indicateurs clients utilisent donc l'identifiant unique de la personne (`customer_unique_id`).
- 610 produits n'ont pas de catégorie. Deux catégories manquaient dans la table de traduction et ont été ajoutées.
- Pour 312 commandes, le montant payé diffère de plus de 1 BRL du total articles + frais de port. L'écart est trop faible pour changer les résultats.

Le périmètre final compte **96 211 commandes livrées** et **93 104 clients**. Les montants sont en réals brésiliens (BRL).

3.2 Techniques SQL utilisées

- Jointures entre plusieurs tables et une vue réutilisable (`v_delivered_orders`) ;
- CTE (`WITH`) pour découper les requêtes longues en étapes lisibles ;
- fonctions de fenêtre : `LAG` pour l'évolution mensuelle, `RANK` pour classer les produits, `NTILE` pour former des groupes ;
- agrégation conditionnelle avec `FILTER` et `CASE WHEN` ;
- segmentation RFM (récence, fréquence, montant) et analyse de cohortes mensuelles.

Exemple : l'évolution du chiffre d'affaires d'un mois sur l'autre.

```sql
WITH monthly AS (
    SELECT DATE_TRUNC('month', order_purchase_timestamp)::date AS month,
           SUM(order_value) AS revenue
    FROM v_delivered_orders
    GROUP BY 1
)
SELECT month,
       revenue,
       ROUND(100.0 * (revenue - LAG(revenue) OVER (ORDER BY month))
            / LAG(revenue) OVER (ORDER BY month), 1) AS mom_growth_pct
FROM monthly
ORDER BY month;
```

4 Résultats

4.1 Ventes

Sur la période, Olist réalise 15,4 millions BRL de chiffre d'affaires, avec un panier moyen de 160 BRL et 1,14 article par commande.

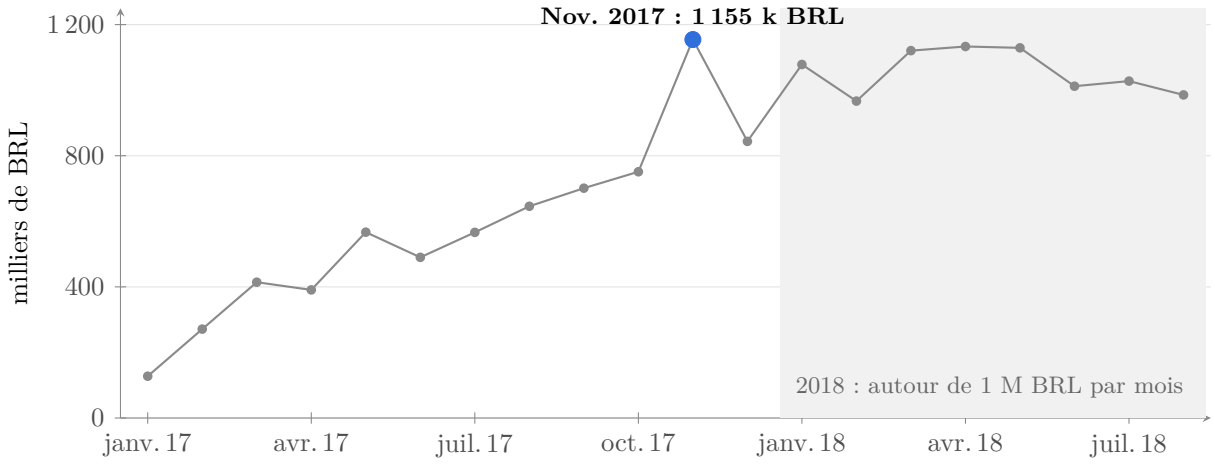


Figure 2: Chiffre d'affaires mensuel des commandes livrées (janv. 2017 – août 2018). Les ventes progressent toute l'année 2017, puis plafonnent en 2018.

De janvier à août, les ventes 2018 sont 2,4 fois plus élevées qu'en 2017 (8,45 millions BRL contre 3,47 millions). Le panier moyen, lui, ne bouge presque pas (160 BRL contre 158 BRL) : la croissance vient du nombre de clients, pas de la taille des paniers. Le pic de novembre 2017 (+54 % par rapport à octobre) coïncide avec le Black Friday.

Les clients commandent surtout en semaine (15 660 commandes le lundi, 10 519 le samedi) et entre 10 h et 22 h.

4.2 Produits et régions

Les 10 premières catégories font 62 % du chiffre d'affaires. Les trois premières sont santé-beauté (9,3 %), montres et cadeaux (8,8 %) et linge de maison (7,8 %).

L'État de São Paulo pèse à lui seul 37 % du chiffre d'affaires. C'est aussi là que les frais de port sont les plus bas : 17 BRL en moyenne, contre 24 à 30 BRL dans les autres grands États.

4.3 Fidélité des clients

C'est le point faible le plus net : **97 % des clients n'ont passé qu'une seule commande**. 2,75 % en ont passé deux, et 0,24 % trois ou plus.

L'analyse de cohortes confirme ce résultat. Quel que soit le mois de la première commande, au plus 2,3 % des clients reviennent dans les six mois.

La segmentation RFM fait ressortir un groupe prioritaire : 20 604 clients à forte valeur, sans commande depuis 334 jours en moyenne. Ils représentent 40 % du chiffre d'affaires.

4.4 Livraison et satisfaction

Une commande arrive en 12,5 jours en moyenne, alors que la date promise est à 23,6 jours. Seules 6,8 % des commandes arrivent en retard. Mais quand c'est le cas, la note chute fortement (tableau 1).

Délai de livraison	Avis	Note moyenne (/5)	Avis de 1 ou 2 étoiles
À l'heure	89 681	4,29	9,3 %
1 à 7 jours de retard	3 611	2,71	49,4 %
8 jours de retard ou plus	2 795	1,70	79,2 %

Tableau 1: Note des clients selon le retard de livraison.

Les États du Nord et du Nord-Est sont les plus touchés. Au Pará, une livraison prend 23,8 jours en moyenne ; au Maranhão, 17,5 % des commandes arrivent en retard.

4.5 Paiements et vendeurs

La carte bancaire couvre 78,5 % des montants payés, avec 3,5 mensualités en moyenne. Le boleto (paiement par bordereau bancaire) représente 18 %.

Le chiffre d'affaires est très concentré : les 10 % de vendeurs les plus actifs (295 vendeurs) génèrent 67 % des ventes.

5 Recommandations

1. **Faire revenir les clients.** Avec seulement 3 % de réachat, la marge de progression est énorme. On peut commencer par les 20 604 clients à forte valeur repérés par la segmentation RFM : e-mail après achat, bon de réduction sur la deuxième commande.
2. **Réduire les retards dans le Nord et le Nord-Est.** Au-delà d'une semaine de retard, la note moyenne tombe sous 2/5. Un transporteur régional ou un entrepôt local protégerait les avis clients.
3. **Sécuriser les vendeurs clés.** Les ventes reposent sur environ 300 vendeurs. Un accompagnement dédié limiterait le risque de perdre l'un d'eux.

6 Limites

- Les données datent de 2016 à 2018. Elles décrivent Olist à cette époque, pas aujourd'hui.
- Il n'y a ni coûts ni marges dans la base : on peut mesurer le chiffre d'affaires, pas la rentabilité.
- Le lien entre retard et mauvaise note est une corrélation. D'autres facteurs, comme la qualité du produit, peuvent jouer.

- La segmentation RFM repose sur des règles simples. Comme presque tous les clients n'ont commandé qu'une fois, la fréquence distingue peu les groupes.
- L'analyse géographique s'arrête au niveau des États.

Fichiers du projet

`01_create_tables.sql`	création des tables, clés et index
`02_load_data.sql`	chargement des fichiers CSV
`03_data_quality.sql`	contrôles de qualité des données
`04_business_analysis.sql`	les 15 questions business